

基于图深度学习的大宗商品价格预测研究

付星星¹ 张 军¹ 秦 岩¹ 宋元超²

¹(山东理工大学管理学院 山东 淄博 255000)

²(山东卓创资讯股份有限公司 山东 淄博 255000)

摘 要 产业链上的多种大宗商品价格之间存在非线性相关性和上下游产品价格联动效应,经典的价格预测算法不能解决此类问题,对此提出一种基于图深度学习的大宗商品价格预测方法。该方法将产品现货价格、期货价格、产量等作为产品节点属性,产品上下游关系用产品结构熵量化作为边属性,CCPI、PPI 作为全局属性,对全产业链上的产品进行价格预测。实验结果验证了该方法的可行性和有效性。与单变量 LSTM、多变量 LSTM 价格预测模型相比,图深度学习价格预测模型表现出更高的准确度。

关键词 图深度学习 价格预测 产业链 大宗商品

中图分类号 TP29

文献标志码 A

DOI:10.3969/j.issn.1000-386x.2021.07.011

COMMODITY PRICE FORECASTING BASED ON GRAPH DEEP LEARNING

Fu Xingxing¹ Zhang Jun¹ Qin Yan¹ Song Yuanchao²

¹(School of Management, Shandong University of Technology, Zibo 255000, Shandong, China)

²(Sublime China Information Co., Ltd., Zibo 255000, Shandong, China)

Abstract There is a non-linear correlation between the prices of various commodities in the industrial chain and the linkage effect between the prices of upstream and downstream products. The classical price prediction algorithms cannot solve such problems. Therefore, this paper proposes a commodity price prediction method based on graph deep learning. In this method, the spot price, futures price and output of products were taken as the node attributes, the upstream and downstream relationship of products was taken as the side attributes by entropy quantification and CCPI and PPI were taken as the global attributes to predict the price of products in the whole industrial chain. The experimental results verify the feasibility and effectiveness of this method. Compared with univariate LSTM and multivariate LSTM price prediction models, the graph deep learning price prediction model shows higher accuracy.

Keywords Graph deep learning Price forecast Industry chain Commodity

0 引 言

随着我国在国际经济贸易中的地位提升,我国已经成为全球最大的大宗商品需求国。除了石油、矿石及各种农产品外,化工产品也是大宗商品的重要组成部分。它可以直接或间接地给能源、纺织、制药、仪器设备等众多行业提供原材料,在我国国民经济发展中处于重要的基础性地位。由于产业链上下游产品数量众多,产业链中上下游产品价格和收益率波动变化往

往存在着一定的关联性,具有显著的联动效应^[2],并且价格波动往往表现为复杂的非线性关系,政府对此进行监管有一定的难度。因此,分析产品及其上下游的历史数据和各项技术指标,并依据相关理论和算法模型来预测产业链产品价格走势具有重要的理论意义和社会价值^[3]。

目前商品价格预测方法的研究经历了从定性到定量,从对数据的简单统计到经济计量,发展到现在基于大数据背景下的对历史数据的学习算法^[4-8]。当前的经典计量经济学方法如 ARIMA、Garch 和 VAR 大多直

接选取产品市场数据为研究对象,可以合理地在特征提取方面对数据进行降维和转换等操作,但是不能有效地将产业联动效应下多产品价格之间的潜在关联因素考虑在内,更不能针对产业链整体价格走势作出判断。并且这些方法在非线性时间序列预测准确性和时序信息利用方面也存在一定的不足。

近年来,一些学者将神经网络等算法应用于图结构数据的分析。Yu 等^[9]将卷积神经网络和递归神经网络引入对交通流的预测中,结果表明该算法具有更高的准确率。Tai 等^[10]针对自然语言表现出将单词自然地组合成短语的句法特性,提出不同于链结构(chain-structured) LSTM 的 tree-LSTM,将其运用于语句间的语义关联程度和语句情感分类的预测,通过与 LSTM 预测结果对比,表明 tree-LSTM 的准确率更高。Zitnik 等^[11]将不同的药作为节点,药与药之间的影响为边构建出药物间互相作用的网络结构图,引入卷积神经网络预测多药的副作用。实验结果表明该模型能够自动学习多药副作用的表征,对多药副作用的预测准确率达到目前最高的 69%。Battaglia 等^[12]针对近年来针对图结构数据的运算模型提出了一个基于实体和关系推理的算法框架-图网络(Graph Network, GN)框架。该模型^[12-15]对非线性序列预测的准确率更高,不仅可以网络中全部节点属性,还可以对节点之间的关系进行推理,对图的全局运作规律进行挖掘。

因此,本文考虑产业链上下游产品间价格存在的联动效应出发,以聚丙烯产业链产品为网络节点,产品间的生产依赖关系为网络中的连边,聚丙烯产业链产品网络抽象为有向无权图 $G(V, E)$ 。利用图深度学习算法对非线性时间序列良好的拟合预测能力开展预测研究。此外,将模型预测结果与传统的机器学习方法进行分析对比,检验本文模型的有效性。

1 图深度学习算法介绍

图深度学习算法是针对非线性时间序列数据设计的一种机器学习算法。图结构数据模型如图 1 所示。在图数据结构中,实体表示成节点,而节点之间的关系被表示成边,系统层面的特征用全局属性表示。




图1 图结构数据模型

图网络结构的主要计算单元是 GN 模块,以图作为输入,在 GN 模块内执行计算,并返回一个图作为输出。 v_i 表示节点, e_k 表示节点之间相连的边, u 表示全局属性。 s_k 和 r_k 分别表示边 e_k 的发送节点和接收节点。

完整的图网络模块的内部结构包含三个更新函数 ϕ_1 、 ϕ_2 、 ϕ_3 ,以及三个聚合函数 ρ_1 、 ρ_2 、 ρ_3 :

$$e'_k = \phi_1^e(e_k, v_{r_k}, v_{s_k}, u) \quad (1)$$

$$\bar{e}'_i = \rho_1^{e \rightarrow v}(E'_i) \quad (2)$$

$$v'_k = \phi_2^v(\bar{e}'_i, v_i, u) \quad (3)$$

$$\bar{e}' = \rho_2^{e \rightarrow u}(E') \quad (4)$$

$$u' = \phi_3^u(\bar{e}', \bar{v}', u) \quad (5)$$

$$\bar{v}' = \rho_3^{v \rightarrow u}(V') \quad (6)$$

式中: $E'_i = \{(e'_k, r_k, s_k)\}_{r_k=i, k=1:N^e}$; $V' = \{v'_i\}_{i=1:N^v}$; $E' = UE'_i = \{(e'_k, r_k, s_k)\}_{k=1:N^e \circ}$

整个算法过程如下:(1) 利用当前的边信息 E 、节点信息 V 、全局信息 U 来生成新的边的信息;(2) 利用新的边信息,生成新的节点信息;(3) 利用新的节点和边信息,生成新的全局信息 U ,即完成整个更新过程。

GN 模块关键的设计原则是:第一,多个实体和实体间的复杂关系可以灵活地表征;第二,模块内部结构可根据需要配置;第三,可组合的多模块框架,节点、边、全局属性的状态更新所需信息、更新顺序及更新函数和聚合函数的选用均根据实际情况进行设计^[12]。

2 方法设计

2.1 聚丙烯产业链产品网络构建

大宗商品包括能源商品、基础原材料和农副产品三个类别。传统的农副产品和基础原材料并不能依据生产依赖关系建立起完备的生产关系网络。

数量众多的大宗化工产品之间存在直接或间接的生产关系,构成了一个完备的图结构。鉴于此本文以产业链内产品为网络节点,产品间的生产依赖关系为网络中的连边,将整个化工产品网络抽象为有向无权图 $G(V, E)$ 。其中 $V = \{v_1, v_2, \dots\}$ 中的每一个节点代表了一种化工产品, $E = \{e_{ij} \in E \mid e_{ij} < v_i, v_j >, v_i, v_j \in V\}$ 是产品间的生产依赖关系集合, e_{ij} 表示产品 v_i 是 v_j 的原材料。聚丙烯产业链作为化工市场的晴雨表,产业链内上游包含原油、天然气、煤炭三大能源材料,下游产成品涉及众多领域,已经成为我国各行各业发展不可或缺的一部分^[7]。因此,本文选取聚丙烯产业链作为研究对象,其产业链网络结构图如图 2 所示。




图2 聚丙烯产业链网络结构图

2.2 基于图深度学习的价格预测模型

聚丙烯产业链产品价格数据是一种金融时间序列,与上下游产品间价格联动密切,其波动表现出显著的非线性和不稳定性。为了能较准确地预测聚丙烯产业链上产品的价格,本文选取在时间序列预测方面表现优秀的 LSTM 作为 GN 模块内的更新函数,整体结构如图 3 所示,整个 GN 模块由输入层($V^t, V_{hid}^t, U^t, U_{hid}^t, E^t, E_{hid}^t$)、更新函数(LSTM)和输出层(V^{t+1}, V_{hid}^{t+1})组成。

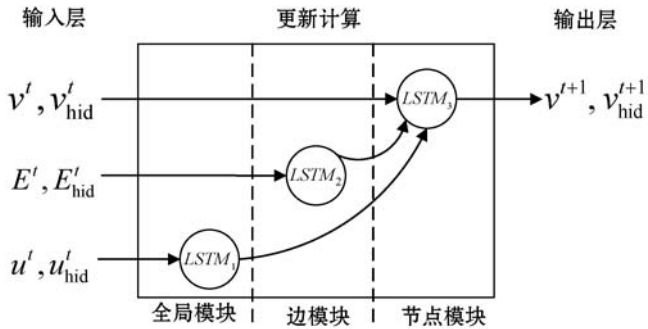


图3 价格预测模型 GN 模块

2.2.1 输入层

输入层负责对节点输入的节点属性、边属性、全局属性进行相应的处理,满足网络输入的要求。根据聚丙烯产业链中各产品市场特征,获得不同节点的现货价格(sp)、期货价格(fp)、产量(op)等作为节点属性。全局属性选取中国大宗商品指数(CCPi)、生产价格指数(PPI)作为对产业链产品所处市场宏观环境变化情况^[16];此外,根据文献[17],本文选取产品网络结构熵(se)作为边属性,计算公式如下:

$$E = - \sum_i p(i) \log p(i) \tag{7}$$

式中: $p(i)$ 为节点*i*的度概率分布。节点度是指和该节点相连的边的条数,网络结构熵衡量的是网络中某一节点的节点度的网络节点度分布中的重要性^[17]。

2.2.2 更新计算

图网络模块内采用 LSTM 细胞作为更新函数, $U^t, U_{hid}^t, E^t, E_{hid}^t$ 经过 LSTM 计算得到的输出值与 V^t, V_{hid}^t 共同作为节点属性更新的输入值,对 $t+1$ 时刻的 V^{t+1}, V_{hid}^{t+1} 进行预测价格预测模型算法的过程如下:

步骤1 在 wind 数据库中选取各产品数据,并按

照节点属性、边属性、全局属性对数据进行分类,结合 LSTM 对输入数据的要求,对数据进行归一化处理。

步骤2 在 t 时间步,将各节点的全局属性 $\{CCPI_k^t, PPI_k^t\}_{k=1;N^v}$ 作为全局模块的更新函数 $LSTM_1$ 的输入,得到各节点 $t+1$ 时刻的全局属性更新值 $\{CCPI_k^{t+1}, PPI_k^{t+1}\}_{k=1;N^v}$ 。

步骤3 在 t 时间步,将各节点的边属性 $\{se_k^t\}_{k=1;N^v}$ 作为边模块的更新函数 $LSTM_2$ 的输入,得到各节点 $t+1$ 时刻的边属性的更新值 $\{se_k^{t+1}\}_{k=1;N^v}$ 。

步骤4 在 t 时间步,将各节点的节点属性 $\{sp_k^t, fp_k^t, op_k^t, \dots\}_{k=1;N^v}$ 、更新后的边属性 $\{se_k^{t+1}\}_{k=1;N^v}$ 、全局属性 $\{CCPI_k^{t+1}, PPI_k^{t+1}\}_{k=1;N^v}$ 作为节点模块的更新函数 $LSTM_3$ 的输入,得到各节点 $t+1$ 时刻的边属性现货价格的更新值 $\{sp_k^{t+1}\}_{k=1;N^v}$ 。

步骤5 训练完成后,将测试数据作为输入,输出值即为现货价格的预测值。

N 表示节点的个数,更新函数 $LSTM_1, LSTM_2, LSTM_3$ 均在 Keras 框架下进行实现,分别进行单独训练,均选取 MAE 作为训练目标函数,Adam 作为优化函数。

2.2.3 输出层

将归一化数据还原到原始尺度, $t+1$ 时刻产品预测价格为:

$$\hat{y} = \{sp_k^{t+1}\}_{k=1;10} \tag{8}$$

3 实验

3.1 实验数据集

根据聚丙烯产业链中各产品市场特征的不同,从 wind 数据库中获得 2014 年 1 月—2018 年 12 月的不同节点的节点属性、边属性、全局属性的月度数据,如表 1 所示。选取 2014 年 1 月—2018 年 3 月的 51 个月的统计数据作为训练集;2018 年 4 月—11 月的产品价格作为测试集。

表1 t时刻输入数据

节点	节点属性		边属性	全局属性
原油	现货价格 期货收盘价	库存环比, 运输指数	结构熵	CCPI PPI
天然气	现货价格 期货收盘价	对外依存度	结构熵	CCPI PPI
煤炭	现货价格 期货收盘价	产量, 消费量	结构熵	CCPI PPI

续表 1

节点	节点属性		边属性	全局属性
甲醇	现货价格 期货收盘价	库存, 对外依存度	结构熵	CCPI PPI
丙烯	现货价格	—	结构熵	CCPI PPI
丙烷	现货价格 库存	—	结构熵	CCPI PPI
聚丙烯	现货价格 期货收盘价	聚丙烯指数, 产量	结构熵	CCPI PPI
bopp	现货价格	—	结构熵	CCPI PPI
cpp	现货价格	—	结构熵	CCPI PPI
PP 注塑	现货价格	—	结构熵	CCPI PPI

3.2 数据归一化处理

采用 min-max 归一化对原始数据处理,消除量纲差异。对原始数据的线性变换,使结果落到[0,1]区间。转换公式如下:

$$X = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \tag{9}$$

式中: x_{\max} 表示样本数据属性中的最大值; x_{\min} 表示样本数据属性中的最小值; x 为属性原始数据; X 为归一化后的数据。

3.3 LSTM 参数选定

LSTM 的网络结构和参数设置决定着模型最终的预测性能。经过调优最终确定的三组实验内 LSTM 的参数如表 2 所示。

表 2 各实验 LSTM 参数设定

LSTM 参数	单变量 LSTM	多变量 LSTM	图深度学习
Activation	tanh	tanh	tanh
Dropout	0	0.1	0.1
Timestep	1	1	1
Batch_size	1	1	1
Epochs	200	250	200
目标函数	MAE	MAE	MAE
优化函数	Adam	Adam	Adam
lr	0.001	0.001	0.001

3.4 模型评价指标

本文选取平均绝对误差 (MAE)、均方根误差 (RMSE) 和平均绝对百分比误差 (MAPE) 作为评价指标对模型预测结果进行定量评价。MAE、RMSE、MAPE

的数值越小,表明模型预测结果与真实值偏差越小,结果越准确^[18]。具体公式定义如下:

$$MAE = \frac{1}{N} \sum_{n=1}^N |\hat{y}_n - y_n| \tag{10}$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{n=1}^N (\hat{y}_n - y_n)^2} \tag{11}$$


$$MAPE = \frac{1}{N} \sum_{n=1}^N \frac{|\hat{y}_n - y_n|}{y_n} \tag{12}$$

式中: N 表示实验预测的次数; \hat{y}_n 为模型预测值; y_n 为真实值。


3.5 价格预测结果比较与分析

为了验证该模型的预测性能,设置两组对照实验:第一组是单变量 LSTM 价格预测,输入为产品现货价格,更新函数为 LSTM,输出为产品现货价格预测值;第二组是多变量 LSTM 价格预测,输入为产品的多个属性值,更新函数为 LSTM,输出为产品现货价格预测值。

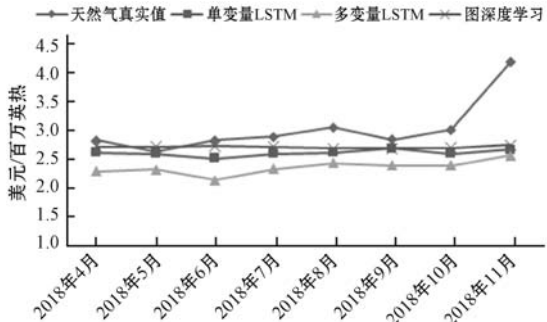
相关模型的预测结果如图 4 所示。



(a) 聚丙烯预测值比较




(b) 原油预测值比较




注:1 英热 = 1 055.055 85 焦耳


(c) 天然气预测值比较



(d) 煤炭预测值比较




(e) 甲醇预测值比较




注:1 加仑≈3.785 升。


(f) 丙烷预测值比较




(g) 丙烯预测值比较



(h) bopp 预测值比较



(i) cpp 预测值比较



(j) PP 注塑预测值比较

图4 聚丙烯产业链各产品预测结果比较

由图4(a) - 图(c)的对聚丙烯、原油、天然气现货价格的预测可见,图深度学习模型预测值在整体走势与真实值较为符合,但在真实值曲线波动剧烈处,预测准确度表现较差。在产业链价格波动单向传导的情况下,对产业链上游价格进行预测时,图深度学习预测模型无法获得更多的市场信息,因此无法对产品价格的波动进行有效的预测。观察中下游产品价格预测值可知,在对甲醇、丙烯的预测中,图深度学习模型的预测结果在8个月的时间段上非常接近真实值,对产品丙烯、cpp、PP 注塑的预测表现优越,可见当充分掌握产业链上游产品信息,产品价格稳定时,图网络模型的预测更加精确。在对 bopp 的预测中,由于缺少产品自身市场信息,当产品价格发生波动时,图深度学习预测模型预测数值偏差较大。

根据表3所示的评价结果,在对产业链上原油、甲醇、丙烯、PP 注塑产品的预测中,预测误差在 MAE、RMSE、MAPE 评价标准下均优于其他两种预测模型。在 MAE 评价标准下,图深度学习模型对天然气、cpp 产品价格的预测表现稍差于其他预测模型,对产业链上其他产品的预测均优于其他预测模型。在 RMSE 评价标准下,单变量 LSTM 预测模型仅对 bopp 产品价格预测具有微弱优势;对产业链上其他产品的价格预测,图网络价格预测模型均表现优越,表明了深度学习模型在获取足够的市场信息的情况下,能够准确预测因市场环境变化带来的价格的异常变化。在 MAPE 评价标准下,对聚丙烯及上游产品天然气、煤炭、丙烷的预

测中,图网络模型表现出微弱的劣势,而对下游产品丙烯、cpp、PP 注塑其预测效果显著。

表 3 各预测模型评价指标比较

评价指标	节点	单变量 LSTM	多变量 LSTM	图深度学习
MAE	原油	5.610	5.894	4.510
	天然气	0.271	0.470	0.343
	煤炭	13.887	16.376	5.776
	甲醇	199.669	197.592	185.264
	丙烷	0.078	0.067	0.061
	丙烯	100.282	20.862	0.521
	聚丙烯	399.675	480.269	347.575
	bopp	414.239	554.300	407.811
	cpp	228.814	1 503.108	260.688
	PP 注塑	24.806	8.238	0.618
RMSE	原油	6.496	6.552	5.767
	天然气	0.478	0.696	0.470
	煤炭	15.507	17.665	0.470
	甲醇	284.340	238.276	212.433
	丙烷	0.093	0.079	0.069
	丙烯	100.282	26.244	0.524
	聚丙烯	453.815	555.938	447.087
	bopp	491.200	597.516	503.942
	cpp	413.585	1 607.676	390.357
	PP 注塑	24.806	8.902	0.618
MAPE	原油	8.734	9.536	8.513
	天然气	11.799	22.118	12.887
	煤炭	0.980	1.442	1.210
	甲醇	7.532	8.018	5.663
	丙烷	8.731	0.482	8.830
	丙烯	1.598	6.410	0.009
	聚丙烯	3.743	3.511	5.769
	bopp	2.810	2.716	5.022
	cpp	3.893	4.657	2.377
	PP 注塑	0.251	0.164	0.005

由此可见,对于产业链上大宗商品的价格预测,在整体表现上,基于图深度学习的价格预测模型表现更好、预测精度更高。

4 结 语

本文针对大宗商品价格预测问题,在考虑大宗商品价格波动的非线性和上下游联动的基础上,在一般

的单变量 LSTM 和多变量 LSTM 价格预测模型上加入了产品的边属性及全局属性,提出了基于图深度学习的价格预测模型。使用 wind 数据库中的产品数据进行实验,结果表明从产业链全局视角出发,建立产品价格关系图基于图深度学习的价格预测模型对产业链上的多种产品价格预测具有更高的准确度。

下一步工作一方面将在产业链上游价格波动向下游单向传导的基础上,考虑价格波动的双向传导,设计实验;另一方面,由于化工行业主要产品种类繁多,完整的产品网络体系结构庞大,现阶段尚未获取更多的产品数据,因此将在实验中加入产业链上产品的其他属性,完善图网络结构,进一步扩大实验的数据规模,达到更好的训练效果。

参 考 文 献

[1] 史建楠,邹俊忠,张见,等. 基于 DMD-LSTM 模型的股票价格时间序列预测研究[J]. 计算机应用研究,2020,37(3): 662 – 666.

[2] Rotenberg P J J. The excess co-movement of commodity prices[J]. The Economic Journal,1990,100(403):1173 – 1189.

[3] 裴大卫,朱明. 基于多因子与多变量长短期记忆网络的股票价格预测[J]. 计算机系统应用,2019,28(8):30 – 38.

[4] 张学武,杨祺. 2007 年国际市场石油价格变化特点分析及后期走势预测[J]. 中国能源,2007,29(8):26 – 28.

[5] 纪钦洪,孙洋洲,于航,等. 基于多元线性回归的碳配额价格预测模型研究[J]. 现代化工,2018,38(4):220 – 224.

[6] Box G E P, Jenkins G M. Time series analysis for casting and control[J]. Journal of Time,1994,31(4):303.

[7] 张丽华,王睿,田振中. 基于 VAR 模型的动力煤价格波动性分析[J]. 经济问题,2016(12):52 – 56.

[8] 于卓熙,秦璐,赵志文,等. 基于主成分分析与广义回归神经网络的股票价格预测[J]. 统计与决策,2018,34(18): 168 – 171.

[9] Yu B, Yin H T, Zhu Z X. Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting[EB]. arXiv:1709.04875,2017.

[10] Tai K S, Socher R, Manning C D. Improved semantic representations from tree-structured long short-term memory networks[EB]. arXiv:1503.00075v3,2015.

[11] Zitnik M, Agrawal M, Leskovec J. Modeling polypharmacy side effects with graph convolutional networks[J]. Bioinformatics,2018,34(13):457 – 466.

[12] Battaglia P W, Hamrick J B, Bapst V, et al. Relational inductive biases, deep learning, and graph networks[EB]. arXiv:1806.01261,2018.

[13] Scarselli F, Gori M, Tsoi A C, et al. The graph neural net-

work model [J]. IEEE Transactions on Neural Networks, 2009, 20(1):61-80.

[14] Wu Z H, Pan S R, Chen F W, et al. A comprehensive survey on graph neural networks [J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(1):4-24.

[15] Zhou J, Cui G Q, Zhang Z D, et al. Graph neural networks: A review of methods and applications [EB]. arXiv: 1812.08434, 2018.

[16] 肖争艳,王兆瑞,陈彦斌. 新常态下 PPI 与 CPI 之间产业链价格传导机制研究 [J]. 经济与管理研究, 2019, 40(4): 14-24, 64.

[17] 罗鹏,李永立,吴冲. 利用网络结构熵研究复杂网络的演化规律 [J]. 复杂系统与复杂性科学, 2013, 10(4): 62-68.

[18] 宋刚,张云峰,包芳勋,等. 基于粒子群优化 LSTM 的股票预测模型 [J]. 北京航空航天大学学报, 2019, 45(12): 2533-2542.

(上接第 16 页)

每个表的物理字段表示如下:

(1) 服务商信息表(dt_service)包括服务商表 ID、服务商编号、服务商名称、联系电话、联系地址。

(2) 供应商信息表(dt_supplier)包括供应商表 ID、供应商编号、供应商名称、联系电话、联系地址。

(3) 车辆信息表(dt_cars)包括车辆表 ID、车辆编号、车辆品牌、车辆型号、车架号、生产地址、出厂日期、生产商名称、生产商编号、供应商编号、客户编号、鉴定单编号、服务商编号。

(4) 客户信息表(dt_customer)包括客户表 ID、客户编号、客户姓名、联系电话、联系地址、服务商编号。

(5) 保养单信息表(dt_by)包括保养单 ID、保养单编号、客户名称、车辆型号、保养项目、保养费用、审核状态、服务商编号、鉴定单编号。

(6) 维修单信息表(dt_wx)包括维修单 ID、维修单编号、客户名称、车辆型号、更换配件名型号、更换配件供应商、更换配件价格、服务商编号、鉴定单编号。

(7) 鉴定单信息表(dt_appraise)包括鉴定单 ID、鉴定单编号、车辆型号、更换配件名称、鉴定结果、供应商编号、服务商编号。

(8) 旧配件信息表(dt_old_fittings)包括旧配件单 ID、旧配件编号、旧配件名称、旧配件型号、旧配件数量、旧配件状态、鉴定单编号。

2.3 系统实现

面向互联网+多核服务价值链业务协同系统采用.net C#语言进行开发,图4为系统的部分业务界面。



图4 系统部分业务模块界面

3 结 语

本文通过对“互联网+”新形式下,多核服务价值链上的汽车制造厂、服务商、供应商、客户等各方对优质服务的个性化需求的分析,明确各个角色相关系统功能需求,设计实现了面向互联网+多核服务价值链业务协同系统。这不仅解决传统售后服务的协同业务,还实现了管家式交钥匙维修和基于大数据分析的主动维护提醒,为汽车制造厂和维修服务商开展主动服务提供支持,从而进一步提高售后服务的协同效率,降低了服务成本。

参 考 文 献

[1] 孙小亮. 基于汽车售后供应链的配件库存管理研究 [D]. 北京:北京工业大学, 2014.

[2] 郎学红. 中美汽车售后服务对比 [R]. 上海: 2018 汽车售后市场高峰论坛, 2018.

[3] 赵艳丰. 汽车售后业的发展方向——解读美国模式 [J]. 汽车与配件, 2014(42): 44-45.

[4] 李海. 汽车服务行业未来发展方向猜想 [J]. 汽车工业研究, 2014(4): 38-40.

[5] 艾媒生活与出行产业研究中心. 2019 年汽车后市场分析与发展趋势研究报告 [R/OL]. (2019-05-17). [2019-09-18]. <https://www.iimedia.cn/c400/64394.html>.

[6] 黄超. “互联网+汽车后市场”的发展趋势 [J]. 汽车维护与修理, 2015(9): 36-38.

[7] 王清进. 支持产业链协同的汽车配件销售预测系统的研究与实现 [D]. 成都: 西南交通大学, 2017.

[8] 彭朝阳. 汽车售后服务质量评价技术研究 [D]. 成都: 西南交通大学, 2017.

[9] 杨添琴. 基于汽车产业链协同平台的配件需求预测系统研究与实现 [D]. 成都: 西南交通大学, 2015.